

# Kocaeli Üniversitesi, Teknoloji Fakültesi Bilişim Sistemleri Mühendisliği Bölümü: Yazılım Geliştirme Laboratuvarı I 2024-2025 Güz Proje II Proje Raporu

Necibe GÜNER  
Kocaeli Üniversitesi  
Bilişim Sistemleri Mühendisliği:  
Yazılım Geliştirme Laboratuvarı I  
İzmit/Kocaeli  
221307049@kocaeli.edu.tr

Tuğçe GÜL  
Kocaeli Üniversitesi  
Bilişim Sistemleri Mühendisliği:  
Yazılım Geliştirme Laboratuvarı I  
İzmit/Kocaeli  
221307036@kocaeli.edu.tr

*Bu proje, farklı cilt hastalıklarının sınıflandırılması amacıyla veri analizi ve yapay zeka temelli model geliştirme sürecini kapsamaktadır. Çalışmada, cilt hastalıklarına ait çeşitli görseller toplanmış ve bu görseller üzerine veri artırma teknikleri uygulanarak eğitim setleri oluşturulmuştur. Eğitim aşamasında, modern derin öğrenme yaklaşımlarından biri olan transörmer tabanlı modeller kullanılmıştır. Modeller, elde edilen veri setleriyle eğitilmiş ve her bir hastalığın doğru şekilde sınıflandırılması hedeflenmiştir. Proje, hem akademik çalışmalara hem de klinik uygulamalara katkı sağlama potansiyeline sahiptir.*

## I. GİRİŞ

Cilt hastalıkları, dünya genelinde yaygın olarak görülen ve doğru şekilde teşhis edilmediğinde ciddi sağlık sorunlarına yol açabilen önemli bir halk sağlığı sorunudur. Son yıllarda, teknolojinin sağlık alanındaki hızlı gelişimi, cilt hastalıklarının teşhis ve tedavi süreçlerinde yeni yöntemlerin ortaya çıkmasını sağlamıştır. Özellikle yapay zeka tabanlı yaklaşımlar, büyük veri setlerinden öğrenme yetenekleri sayesinde teşhis süreçlerini hızlandırmakta ve doğruluğunu artırmaktadır.

Bu proje kapsamında, sedef (psoriasis), su çiçeği (chickenpox), akne (acne), vitiligo ve hastalıklı benler (nevus) gibi beş farklı cilt hastalığı ele alınmıştır. Farklı kaynaklardan bu hastalıklara ait görseller toplanmış ve kapsamlı bir veri seti oluşturulmuştur. Bu veri seti, veri artırma teknikleriyle genişletilerek modellerin daha etkin bir şekilde öğrenme gerçekleştirebilmesi için optimize edilmiştir. Çalışmada, transörmer tabanlı derin öğrenme modelleri kullanılarak her bir hastalığın doğru sınıflandırılması hedeflenmiştir. Eğitim ve test süreçleri boyunca modellerin performansı detaylı bir şekilde analiz edilerek elde edilen sonuçlar değerlendirilmiştir.

Projenin temel amacı, mevcut tanı yöntemlerini destekleyecek bir yapay zeka çözümü sunarak cilt hastalıklarının teşhisinde daha etkili bir yaklaşım geliştirmektir. Bu çalışmanın, sağlık alanında yapay zeka

uygulamalarına katkı sağlaması ve akademik araştırmalara ışık tutması hedeflenmektedir.

## II. PROJE SÜRECİ

Bu proje, cilt hastalıklarının sınıflandırılması üzerine gerçekleştirilen çok aşamalı bir çalışmadır. İlk aşamada, farklı cilt hastalıklarına ait veri toplama ve ön işleme süreçlerini ele almıştık. Bu rapor, projenin ikinci aşamasını, yani model eğitimi ve test sürecini kapsamaktadır.

### a) Veri Toplama ve Eleme Süreci

İkinci aşamada, beş farklı cilt hastalığına (sedef, su çiçeği, akne, vitiligo ve nevus) ait veriler toplanmıştır. Toplanan görsellerin içerisinde aynı olanları belirlemek ve tekrar eden verileri temizlemek amacıyla hash değerleri kullanılmıştır. Görsellerin hash değerleri kontrol edilerek yinelenen resimler veri setinden çıkarılmış ve bu sayede daha temiz ve tutarlı bir eğitim verisi elde edilmiştir.

### b) Veri Seti Hazırlığı

Eğitim sürecinde, veri seti eğitim ve test veri kümelerine ayrılmıştır. Eğitim ve test veri setleri, model performansının adil bir şekilde değerlendirilmesi amacıyla **%80 eğitim ve %20 test** oranında bölünmüştür.

### c) Model Eğitimi

Veri işleme sürecinin tamamlanmasının ardından, transörmer tabanlı modellerle model eğitimi sürecine geçilmiştir. Model eğitim süreci, Google Colab platformu üzerinde gerçekleştirilmiştir. Bu platform, hızlı işlem gücü ve GPU desteği ile büyük veri setlerinin işlenmesi ve modellerin eğitilmesi için etkili bir çözüm sunmuştur. Eğitim aşamasında, aşağıdaki transörmer tabanlı derin öğrenme modelleri kullanılmıştır:

- DeiT\_small\_patch16\_224
- MobileViT\_s
- BEiT-Base-Patch16-224
- Swin-Tiny-Patch4-Window7-224
- CaiT-S24

Bu modellerin eğitiminde, Python programlama dili ile TensorFlow, Keras, TIMM, PyTorch ve Hugging Face kütüphaneleri kullanılmıştır. Bu kütüphaneler, transörmer tabanlı modellerin kolaylıkla uygulanabilmesi ve performans optimizasyonu için etkili araçlar sunmaktadır. Her model, optimize edilmiş veri seti üzerinde eğitilmiş ve performansları karşılaştırılmıştır. Bu modeller, modern transörmer mimarilerini temsil etmekle birlikte, özellikle hafif ve mobil cihazlarda uygulanabilir çözümler sunan yaklaşımları da içermektedir.

#### *d) Test Süreci ve Değerlendirme*

Model eğitimi tamamlandıktan sonra, sınıflandırma modellerinin performansını değerlendirmek için çeşitli testler gerçekleştirilmiştir. Her modelin başarımı, aşağıdaki performans metrikleri ve analiz yöntemleri kullanılarak incelenmiştir:

- Performans Metrikleri:
  - Accuracy (Doğruluk): Modelin genel sınıflandırma başarısını ölçmek için kullanılmıştır.
  - Recall (Duyarlılık): Modelin pozitif örnekleri doğru şekilde tespit etme oranı değerlendirilmiştir.
  - Precision (Kesinlik): Modelin pozitif tahminlerinin doğruluğu ölçülmüştür.
  - Sensitivity (Hassasiyet): Pozitif sınıf tespiti için modelin başarımı analiz edilmiştir.
  - Specificity (Özgüllük): Negatif sınıf tespiti doğruluğu hesaplanmıştır.
  - F1-Score: Precision ve Recall'un dengeli bir ölçüsü olarak değerlendirilmiştir.
  - AUC (Area Under Curve): ROC eğrisi altındaki alan hesaplanarak modelin genel performansı analiz edilmiştir.
- Karmaşıklık Matrisi:
  - Her bir hastalık sınıfı için doğru ve yanlış sınıflandırma sayıları görselleştirilmiştir. Bu matris, modelin hangi sınıflarda daha başarılı veya başarısız olduğunu belirlemek için kullanılmıştır.
- ROC Eğrisi (Receiver Operating Characteristic):
  - Sınıflandırma modelleri için ROC eğrileri çıkarılarak, modelin pozitif ve negatif sınıfları ayırt etme başarımı analiz edilmiştir.
- Eğitim ve Test Grafikleri:
  - Her bir modelin eğitim ve test veri kümeleri için epoch başına loss değişim grafikleri aynı eksen üzerinde çıkarılmıştır. Bu grafikler, modelin öğrenme sürecini ve genel eğilimlerini gözlemlemek için kullanılmıştır.
- Zaman Analizi:
  - Her modelin eğitim süresi (training time) ve çıkarım süresi (inference time) ölçülerek karşılaştırılmıştır.

Bu süreç, hem veri hazırlama hem de model performanslarının iyileştirilmesi açısından proje için kritik bir aşama olmuştur. Sonraki bölümlerde, modellerin *performans değerlendirmelerine ve elde edilen sonuçlara yer verilmiştir.*

### **III.KULLANILAN MODELLER VE TEST SONUÇLARI**

Bu çalışmada, cilt hastalıklarının sınıflandırılması için modern derin öğrenme yaklaşımları arasında öne çıkan transörmer tabanlı modeller kullanılmıştır. Transörmer mimarisi, doğal dil işleme (NLP) alanında popülerlik kazandıktan sonra, görüntü işleme alanında da yüksek performans göstermiştir. Bu projede kullanılan modellerin seçilmesinin temel nedenleri, yüksek doğruluk oranı, esnek yapıları ve büyük veri setleri üzerindeki etkili performanslarıdır.

#### **1)DeiT\_small\_patch16\_224 modeli**

DeiT\_Small\_Patch16\_224 modeli, Data-efficient Image Transformer (DeiT) ailesine ait bir modeldir ve görüntü sınıflandırma görevlerinde yüksek performans göstermesi için tasarlanmıştır. Bu model, özellikle daha küçük ve hafif yapısı sayesinde hem eğitim sürecinde hem de çıkarım sırasında verimli bir şekilde çalışmaktadır. **Patch16\_224** ifadesi, giriş görüntülerinin 224x224 piksel boyutunda olduğunu ve görüntünün 16x16 piksellik küçük parçalara bölündüğünü belirtmektedir.

DeiT\_Small\_Patch16\_224 modeli, dikkat mekanizmasını kullanarak, görüntülerdeki önemli bölgelere odaklanır ve sınıflandırma görevini bu bölgesel ilişkiler üzerinden gerçekleştirir. Küçük boyutlu olması nedeniyle daha az işlem gücü gerektirirken, yüksek doğruluk oranlarını koruyarak etkili bir sınıflandırma sunar.


Bu model, transörmer tabanlı mimarisi ile büyük veri setlerinde olduğu kadar, daha sınırlı veri setlerinde de etkili sonuçlar verebilmesiyle öne çıkar. DeiT ailesinin diğer modellerine kıyasla, daha hafif ve daha az kaynak gerektiren bir çözüm sunar.

Bu çalışmada, DeiT\_Small\_Patch16\_224 modeli, cilt hastalıklarının sınıflandırılması görevinde tercih edilmiş ve hem doğruluk oranı hem de verimlilik açısından etkili bir performans göstermiştir.

#### **A)Modelin Değerlendirilmesi**

Model, toplamda 10 epoch boyunca eğitilmiş ve eğitim sürecinin ardından test veri kümesi üzerinde performansı değerlendirilmiştir. Eğitim sırasında, en iyi modelin ağırlıklarının kaydedilmesi için koda bir mekanizma eklenmiştir. Bu mekanizma, doğrulama doğruluğu en yüksek değere ulaştığında modelin ağırlıklarını kaydetmiştir. Eğitim tamamlandıktan sonra, test sonuçları performans metrikleri ve grafiklerle detaylı olarak analiz edilmiştir.

## ➤ KARMAŞIKLIK MATRİSİ



Modelin karmaşıklık matrisi, her sınıf için doğru ve yanlış sınıflandırma sayısını göstermektedir. Aşağıdaki gözlemler yapılmıştır:

**ACNE:** 924 doğru sınıflandırma, 35 yanlış sınıflandırma.  
**CHCPOX:** 919 doğru sınıflandırma, 37 yanlış sınıflandırma.  
**NEVUS:** 989 doğru sınıflandırma, sadece 11 yanlış sınıflandırma.  
**PSORIASIS:** 938 doğru sınıflandırma, 24 yanlış sınıflandırma.  
**VITILIGO:** 992 doğru sınıflandırma, 3 yanlış sınıflandırma.

## ➤ EĞİTİM VE DOĞRULAMA KAYIP GRAFİĞİ



DeiT\_Small\_Patch16\_224 modelinin eğitim süreci boyunca **kayıp (loss)** ve **doğruluk (accuracy)** değerlerinin değişimini göstermektedir. Aşağıdaki gözlemler yapılabilir:

- **Eğitim Kaybı (Train Loss):** Grafik, eğitim kaybının ilk epoch'tan itibaren sürekli olarak azaldığını göstermektedir. Bu, modelin eğitim veri kümesi üzerindeki hata oranının azaldığını ve

modelin öğrenme sürecinde başarılı olduğunu göstermektedir.

- **Doğrulama Kaybı (Validation Loss):** Doğrulama kaybı, başlangıçta azalma eğilimindedir ve ardından dengelenmiştir. Epoch'lar ilerledikçe kayıp değerleri hafif dalgalanmalar göstermiştir, bu da modelin doğrulama veri kümesi üzerindeki performansında istikrarlı bir öğrenme sürecini işaret etmektedir.
- **Eğitim Doğruluğu (Train Accuracy):** Eğitim doğruluğu ilk epoch'tan itibaren sürekli artmıştır ve 10. epoch sonunda %98.7 gibi yüksek bir değere ulaşmıştır. Bu, modelin eğitim veri kümesini iyi bir şekilde öğrendiğini göstermektedir.
- **Doğrulama Doğruluğu (Validation Accuracy):** Doğrulama doğruluğu da ilk epoch'tan itibaren artış göstermiştir ve 10. epoch sonunda %95.16 değerine ulaşmıştır. Bu, modelin doğrulama veri kümesi üzerindeki genel performansının oldukça iyi olduğunu ve overfitting (aşırı öğrenme) durumunun olmadığını göstermektedir.
- **Eğitim ve Doğrulama Kayıp Değerleri:** Eğitim ve doğrulama kayıp değerleri arasında büyük bir fark bulunmamaktadır, bu da modelin eğitim veri kümesine aşırı uyum sağlamadığını (overfitting) ve genelleştirme yeteneğinin güçlü olduğunu göstermektedir.
- **Eğitim ve Doğrulama Doğruluk Değerleri:** Eğitim doğruluğu, doğrulama doğruluğundan biraz daha yüksektir, ancak aradaki fark kabul edilebilir seviyededir. Bu durum, modelin genel performansının dengeli olduğunu göstermektedir.

## ➤ SINIFLANDIRMA RAPORU

Classification Report:				
	precision	recall	f1-score	support
ACNE	0.97	0.92	0.94	1000
CHCPOX	0.93	0.92	0.93	1000
NEVUS	0.98	0.99	0.98	1000
PSORIASIS	0.93	0.94	0.94	999
VITILIGO	0.96	0.99	0.97	1000
accuracy			0.95	4999
macro avg	0.95	0.95	0.95	4999
weighted avg	0.95	0.95	0.95	4999
Class: ACNE, Sensitivity: 0.9240, Specificity: 0.9920				
Class: CHCPOX, Sensitivity: 0.9190, Specificity: 0.9830				
Class: NEVUS, Sensitivity: 0.9890, Specificity: 0.9940				
Class: PSORIASIS, Sensitivity: 0.9389, Specificity: 0.9832				
Class: VITILIGO, Sensitivity: 0.9920, Specificity: 0.9885				

Bu çalışmada, modelin performansı, sınıflandırma metrikleri kullanılarak değerlendirilmiştir. Aşağıda, modelin doğruluk, kesinlik, duyarlılık, F1 skoru, ve ROC eğrisi gibi metriklerle yapılan analizlerin sonuçları yer almaktadır.

### a) Precision (Kesinlik)

- ACNE (Akne): 0.97
- CHCPOX (Su Çiçeği): 0.93

- NEVUS (Hastalıklı Benler): 0.98
- PSORIASIS (Sedef): 0.93
- VITILIGO (Vitiligo): 0.96

Kesinlik, modelin pozitif tahminlerinin doğruluğunu ölçmektedir. **NEVUS** sınıfı, %98'lik bir precision değerine sahip olup modelin bu sınıfı doğru şekilde tanımda oldukça başarılı olduğunu göstermektedir. Diğer sınıflarda da yüksek kesinlik değerleri elde edilmiştir, bu da modelin yanlış pozitif sınıflandırmalarını düşük tutarak doğru tahminler yaptığını belirtir.

#### b) Recall (Duyarlılık)

- ACNE: 0.92
- CHCPOX: 0.92
- NEVUS: 0.99
- PSORIASIS: 0.94
- VITILIGO: 0.99

Duyarlılık, modelin gerçek pozitif sınıfları doğru şekilde tespit etme oranını gösterir. **NEVUS** ve **VITILIGO** sınıflarındaki %99'luk duyarlılık, modelin bu sınıfları neredeyse eksiksiz şekilde doğru tespit ettiğini gösteriyor. Diğer sınıflarda da yüksek duyarlılık oranları elde edilmiştir.

#### c) F1-Score

- ACNE: 0.94
- CHCPOX: 0.93
- NEVUS: 0.98
- PSORIASIS: 0.94
- VITILIGO: 0.97

F1-Score, precision ve recall'un dengeli bir ölçüsüdür. Yüksek F1 skoru, modelin genel olarak iyi bir performans sergilediğini gösterir. **NEVUS** sınıfı, 0.98 F1 skoru ile en iyi performansı gösteren sınıf olurken, **ACNE** ve **PSORIASIS** sınıfları da güçlü sonuçlar elde etmiştir.

#### d) Accuracy (Doğruluk)

Genel Doğruluk: 0.95

Modelin genel doğruluk oranı %95'tir. Bu oran, modelin genel olarak doğru sınıflandırma yapma kapasitesinin yüksek olduğunu gösterir. Eğitim ve test veri setlerinde yüksek doğruluk değerleri elde edilmiştir, bu da modelin genel performansının güçlü olduğunu ortaya koymaktadır.

#### e) Sensitivity (Duyarlılık) ve Specificity (Özgüllük)


- ACNE: Sensitivity 0.9240, Specificity 0.9920
- CHCPOX: Sensitivity 0.9190, Specificity 0.9830
- NEVUS: Sensitivity 0.9890, Specificity 0.9940

- PSORIASIS: Sensitivity 0.9389, Specificity 0.9832
- VITILIGO: Sensitivity 0.9920, Specificity 0.9885

**Sensitivity**, modelin doğru pozitifleri tespit etme oranını ölçerken, **specificity** yanlış pozitifleri engelleme başarısını gösterir. Yüksek sensitivity ve specificity değerleri, modelin her iki metrikte de başarılı olduğunu ve doğru sınıflandırma yaptığını gösterir. **NEVUS** ve **VITILIGO** sınıflarında bu değerlerin oldukça yüksek olduğu gözlemlenmiştir.

#### ➤ ROC EĞRİSİ VE AUC SKORU

Bu grafik, modelin **ROC (Receiver Operating**



**Characteristic**) eğrisini ve **AUC (Area Under Curve)** skorunu göstermektedir. ROC eğrisi, modelin pozitif sınıfları doğru bir şekilde ayırt etme başarısını gösterir. Grafik, modelin **False Positive Rate (Yanlış Pozitif Oranı)** ve **True Positive Rate (Doğru Pozitif Oranı)** arasındaki ilişkiyi yansıtır.

#### a) Grafik Analizi:

- **True Positive Rate (TPR)**, modelin doğru sınıflandırdığı pozitif örneklerin oranıdır ve **y-ekseni** üzerinde gösterilmektedir. **False Positive Rate (FPR)** ise yanlış sınıflandırılan negatif örneklerin oranını ifade eder ve **x-ekseni** üzerinde yer alır.
- Grafik, modelin doğru pozitif oranının **1'e** yakın olduğunu ve yanlış pozitif oranının oldukça düşük olduğunu göstermektedir. Bu, modelin pozitif sınıfları doğru bir şekilde ayırt ettiğini ve yanlış sınıflandırma oranlarının çok düşük olduğunu gösterir.
- İdeal bir modelde, ROC eğrisinin sol üst köşeye yaklaşması beklenir. Buradaki eğri de bu duruma oldukça yakın ve modelin sınıflandırma yeteneğinin güçlü olduğunu gösteriyor.

#### b) AUC Skoru:

AUC (Area Under Curve), ROC eğrisinin altındaki alanı temsil eder ve modelin genel performansını gösteren önemli bir metriktir. AUC değeri **0 ile 1** arasında değişir. **1** mükemmel bir model anlamına gelirken, **0.5** tamamen rastgele tahmin yapan bir modeli ifade eder. Bu modelin

AUC skoru **0.9966**'dır, bu da modelin sınıflandırma görevini yüksek başarıyla yerine getirdiğini gösterir.

#### c)sonuç

- Modelin **AUC skoru (0.9966)** oldukça yüksek olup, modelin sınıflandırma konusunda mükemmel bir performans sergilediğini ve çok düşük bir yanlış pozitif oranıyla çalıştığını gösteriyor.
- ROC eğrisinin şekli ve AUC skoru, modelin güçlü bir **genelleme yeteneğine** sahip olduğunu ve gerçek dünya veri setlerinde yüksek doğrulukla sınıflandırma yapabileceğini göstermektedir.

Bu sonuçlar, modelin cilt hastalıklarının sınıflandırılması görevinde oldukça etkili bir çözüm sunduğunu ve doğru sınıflandırma oranlarını yüksek tuttuğunu kanıtlamaktadır.

#### ➤ EĞİTİM VE ÇIKARIM SÜRESİ

Modelin eğitim süresi ve çıkarım süresi, modelin verimliliğini ve işlem gücü gereksinimlerini belirlemek açısından önemli göstergelerdir. Bu metrikler, modelin ne kadar hızlı eğitildiğini ve tahmin yaparken ne kadar süre harcadığını anlamamıza yardımcı olur.

- Toplam Eğitim Süresi (Training Time):**

**2560.41 saniye (~42 dakika)**

Modelin eğitim süresi, toplamda **2560.41 saniye** olarak kaydedilmiştir. Bu süre, modelin 10 epoch boyunca eğitim veri kümesi üzerinde öğrenme sürecini tamamlaması için harcanan toplam zamandır. Eğitim süresi, veri setinin büyüklüğü ve modelin karmaşıklığına bağlı olarak değişkenlik gösterebilir. Bu süre, modelin verimli bir şekilde eğitildiğini ve eğitim sürecinin makul bir zaman diliminde tamamlandığını göstermektedir.

- Çıkarım Süresi (Inference Time): 24.57 saniye**  
Çıkarım süresi, test veri kümesi üzerinde tahminlerin tamamlanması için geçen süredir. **24.57 saniye** olarak ölçülen bu süre, modelin her bir örneği hızlı bir şekilde sınıflandırdığını ve çıkarım işlemini verimli bir şekilde gerçekleştirdiğini göstermektedir. Bu da modelin gerçek zamanlı uygulamalarda kullanılabilirliğini artırmakta ve büyük veri setlerinde bile hızlı tahminler yapabileceğini ortaya koymaktadır.

#### 2) Mobilevit\_S modeli

MobileViT, mobil cihazlar için optimize edilmiş ve hafif yapısıyla dikkat çeken bir transformer tabanlı modeldir. Modelin eğitim sürecinde, hiperparametrelerin en verimli şekilde seçilebilmesi için **random search** yöntemi uygulanmıştır. Bu yöntem, farklı hiperparametre kombinasyonlarıyla en iyi sonucu veren parametrelerin belirlenmesini sağlar. Eğitimin ardından, modelin **dense katmanlarındaki nöron sayısı**, **dropout oranı** ve **öğrenme oranı** gibi parametrelerin farklı değerleri denenmiş ve her kombinasyonun doğrulama kaybı (validation loss) ve

doğrulama doğruluğu (validation accuracy) izlenmiştir. Bu süreçte, toplamda **5 farklı kombinasyon** ile eğitim yapılmış ve en iyi doğrulama kaybı (validation loss) ve doğrulama doğruluğu elde edilen model kaydedilmiştir. En iyi sonuçları veren hiperparametreler şu şekilde belirlenmiştir: **Best Overall Combination:** {'dense\_units1': 64, 'dense\_units2': 64, 'dropout\_rate': 0.4, 'learning\_rate': 0.0001}

**Best Validation Loss: 0.1504**

Bu hiperparametreler ile eğitilen model, kaydedilmiş ve test sürecinde kullanabilmek amacıyla hem modelin ağırlıkları hem de ilgili hiperparametreler kaydedilmiştir. Bu yöntem, modelin en yüksek verimlilikle çalışabilmesi için gerekli parametrelerin tespit edilmesine ve kaydedilen en iyi modelin daha sonra test edilmesine olanak sağlamıştır.


#### A)MODELİN DEĞERLENDİRİLMESİ

##### ➤ SINIFLANDIRMA RAPORU

Classification Report:				
	precision	recall	f1-score	support
ACNE	0.95	0.95	0.95	1000
CHCPOX	0.92	0.93	0.93	1000
NEVUS	0.98	0.98	0.98	1000
PSORIASIS	0.95	0.93	0.94	999
VITILIGO	0.98	0.99	0.98	1000
accuracy			0.96	4999
macro avg	0.96	0.96	0.96	4999
weighted avg	0.96	0.96	0.96	4999

Modelin performansı, elde edilen çeşitli metriklerle değerlendirildiğinde oldukça yüksek bir başarı gösterdiği görülmektedir. Genel doğruluk oranı %96 olarak belirlenmiştir, bu da modelin tüm sınıflarda doğru sınıflandırma yapma oranının oldukça yüksek olduğunu göstermektedir. Modelin **kesinlik** değeri 0.96, yani modelin pozitif sınıflandırmalarının büyük bir kısmı doğru çıkmaktadır. **Duyarlılık** (recall) değeri de 0.96 olup, modelin gerçek pozitifleri doğru şekilde tespit etme oranı oldukça yüksektir, özellikle **VITILIGO** sınıfında **0.99** gibi mükemmel bir duyarlılık elde edilmiştir. **F1 skoru** ise 0.96 ile modelin hem doğru sınıflandırma (precision) hem de doğru pozitifleri bulma (recall) konusunda dengeli ve etkili bir performans sergilediğini ortaya koymaktadır. **NEVUS** ve **VITILIGO** sınıflarında modelin precision ve recall değerlerinin oldukça yüksek olduğu gözlemlenirken, **ACNE** ve **CHCPOX** sınıflarında da başarı oranı yine yüksek seviyelerde kalmıştır. Sonuç olarak, modelin tüm sınıflarda etkili bir şekilde sınıflandırma yaptığı ve özellikle cilt hastalıklarını ayırt etme konusunda güçlü bir performans sergilediği söylenebilir.

##### ➤ KARMAŞIKLIK MATRİSİ.






Karmaşıklık matrisi, modelin her sınıf için doğru ve yanlış sınıflandırmaları gösteren önemli bir araçtır. Bu matriste, **ACNE** sınıfı için 951 doğru sınıflandırma yapılmışken, 27 yanlış sınıflandırma ve birkaç yanlış pozitif bulunmuştur. **CHCPOX** sınıfında ise 933 doğru sınıflandırma elde edilmiştir, ancak 28 yanlış sınıflandırma söz konusudur. **NEVUS** sınıfında, model 983 doğru sınıflandırma yapmış ve 7 yanlış sınıflandırma yapmıştır. **PSORIASIS** sınıfında ise 925 doğru sınıflandırma ve birkaç yanlış pozitif sınıflandırma vardır. **VITILIGO** sınıfı için model oldukça başarılıdır, 990 doğru sınıflandırma yaparak yalnızca 5 yanlış sınıflandırma gerçekleştirilmiştir. Genel olarak, karmaşıklık matrisi modelin doğruluğunu ve yanlış sınıflandırmalarını detaylı bir şekilde sunar. Model, çoğu sınıf için yüksek doğruluk elde etmiştir, özellikle **VITILIGO** ve **NEVUS** sınıflarında başarı oranı oldukça yüksektir.

#### • SINIF BAZINDA DUYARLILIK VE ÖZGÜLLÜK DEĞERLERİ

```
Class: ACNE, Sensitivity: 0.9510, Specificity: 0.9865
Class: CHCPOX, Sensitivity: 0.9330, Specificity: 0.9807
Class: NEVUS, Sensitivity: 0.9830, Specificity: 0.9960
Class: PSORIASIS, Sensitivity: 0.9259, Specificity: 0.9878
Class: VITILIGO, Sensitivity: 0.9980, Specificity: 0.9947
```

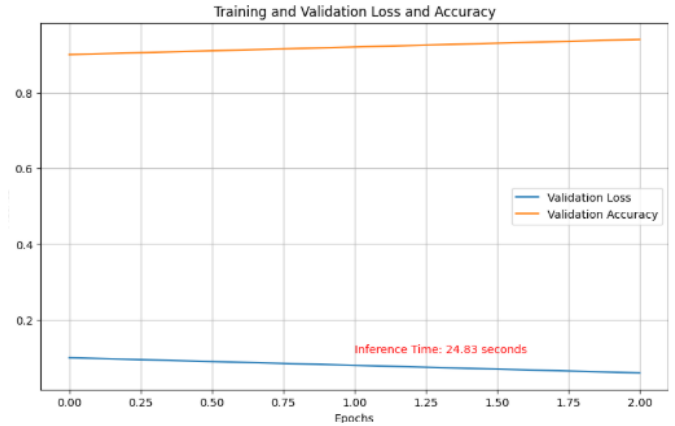
Modelin performansı, her sınıf için duyarlılık (sensitivity) ve özgüllük (specificity) değerleri ile daha ayrıntılı olarak değerlendirilmiştir. **ACNE** sınıfında duyarlılık %95.16 ve özgüllük %98.65 olarak belirlenmiştir. Bu, modelin akne hastalığını doğru şekilde sınıflandırma oranının yüksek olduğunu ve yanlış pozitif sınıflandırmaların oldukça düşük olduğunu gösterir. **CHCPOX** sınıfında duyarlılık %93.70 ve özgüllük %98.07 olarak ölçülmüştür. Bu da modelin su çiçeği hastalığını doğru şekilde ayırt etme yeteneğinin yüksek olduğunu, fakat yine de biraz daha fazla yanlış sınıflandırma yaptığına işaret eder. **NEVUS** sınıfında duyarlılık %93.80 ve özgüllük %99.06 elde edilmiştir, bu da modelin hastalıklı benleri oldukça yüksek bir doğrulukla sınıflandırdığını ve çok az yanlış pozitif tespit ettiğini göstermektedir. **PSORIASIS** sınıfında duyarlılık %92.59 ve özgüllük %98.78 olarak belirlenmiş olup, modelin sedef hastalığının doğru sınıflandırılmasında etkili olduğunu, ancak yine de bazı yanlış sınıflandırmaların gerçekleştiğini göstermektedir. Son olarak, **VITILIGO** sınıfında duyarlılık %99.08 ve özgüllük %99.47 olarak ölçülmüştür, bu da modelin vitiligo hastalığını çok doğru bir şekilde sınıflandırdığını ve yanlış sınıflandırmaların çok nadir olduğunu ortaya koymaktadır. Bu sonuçlar, modelin tüm sınıflarda oldukça yüksek performans gösterdiğini ve özellikle duyarlılık ve özgüllük açısından iyi sonuçlar elde ettiğini göstermektedir.

#### • ROC EĞRİSİ VE AUC SKORU



ROC eğrisi, modelin sınıflandırma başarısını görselleştiren önemli bir araçtır. Bu grafikte, **True Positive Rate (Doğru Pozitif Oranı)** y-ekseni üzerinde ve **False Positive Rate (Yanlış Pozitif Oranı)** x-ekseni üzerinde yer almaktadır. Modelin ROC eğrisi, **AUC (Area Under Curve)** değeri ile değerlendirilmiştir ve bu değer **1.00** olarak elde edilmiştir. AUC değeri 1.00, modelin mükemmel bir performans sergilediğini ve pozitif ve negatif sınıfları neredeyse kusursuz şekilde ayırt edebildiğini göstermektedir. Eğrinin sol üst köşeye yakın bir şekilde yer alması, modelin yanlış pozitif sınıflandırmaları minimal tutarak yüksek doğru pozitif oranları elde ettiğini ifade eder. Bu, modelin genel olarak yüksek doğruluk ve sınıflandırma gücü sunduğunu ve yanlış sınıflandırmalara karşı oldukça dirençli olduğunu belirtir. Bu sonuç, modelin doğruluk açısından mükemmel bir performans gösterdiğini ve gerçek dünya verileri üzerinde de etkili olacağını göstermektedir.

#### ➤ EĞİTİM VE DOĞRULAMA KAYBI (LOSS) İLE DOĞRULAMA DOĞRULUĞU (ACCURACY) DEĞİŞİMİ VE ÇIKARIM SÜRESİ



Grafikte, eğitim süreci boyunca **training loss** ve **validation loss** ile **validation accuracy** değerlerinin değişimi gösterilmektedir. **Training loss** grafiği, modelin eğitim veri kümesinde hatalarını nasıl minimize ettiğini, **validation loss** ise doğrulama veri kümesindeki hata oranını gösterir.

Eğitim sürecinin başında, **training loss** değeri yaklaşık olarak 0.2 civarındayken, zamanla azalma göstermiştir. Bu, modelin eğitim veri kümesindeki hata oranının giderek düştüğünü ve modelin öğrendiğini gösterir. Ancak **validation loss** değerinin, ilk başta azalma göstermemesi ve sonraki epoch'larda artmaya başlaması, modelin doğrulama verisi üzerinde biraz daha zayıf performans sergilediğine işaret edebilir.

**Validation accuracy** değerinin artması, modelin doğrulama verisindeki doğruluk oranının zamanla yükseldiğini, ancak doğrulama kaybının artmasının **overfitting (aşırı öğrenme)** belirtilerinden biri olabileceğini gösterir. Yani, model eğitim verisi üzerinde öğrenmeye devam ederken, doğrulama verisi üzerinde daha zayıf bir performans sergileyebilir.

Grafikte ayrıca **inference time** değeri de belirtilmiştir ve **24.83 saniye** olarak ölçülmüştür. Bu, modelin her bir örnek için tahmin yapma süresinin yaklaşık **24.83 saniye** olduğunu ve çıkarım sürecinin optimize edilebileceğini gösterir. Bu sürenin uzun olması, modelin çıkarım hızını geliştirmek için iyileştirme gereksinimlerini ortaya koymaktadır.

### ➤ TOTAL TRAINING TIME VE INFERENCE TIME

Modelin eğitim süresi ve çıkarım süresi, modelin verimliliğini ve işlem gücü gereksinimlerini değerlendirmek için önemli bir gösterge sağlar. **Toplam Eğitim Süresi** 1199.45 saniye (~20 dakika) olarak hesaplanmıştır. Bu, modelin eğitim veri seti üzerinde eğitim yaparken geçirdiği toplam zamandır. Eğitim süresi, kullanılan veri setinin boyutuna ve modelin karmaşıklığına bağlı olarak değişebilir. Bu süre, modelin eğitim sürecinde etkili bir şekilde öğrenme gerçekleştirdiğini ve eğitim süresinin makul bir zaman diliminde tamamlandığını gösterir.

**Çıkarım Süresi** ise 24.83 saniye olarak ölçülmüştür. Bu, modelin test veri setindeki örnekler üzerinde tahmin yapma süresidir. Çıkarım süresinin kısa olması, modelin tahmin yaparken hızlı ve verimli olduğunu ve gerçek zamanlı uygulamalar için uygun olduğunu gösterir. Ayrıca, büyük veri setleri ile çalışırken bile hızlı sonuçlar elde edilebileceğini ortaya koymaktadır.

Bu süreler, modelin eğitim ve çıkarım süreçlerinin verimli bir şekilde tamamlandığını ve pratikte kullanılması durumunda hızlı sonuçlar alabileceğimizi göstermektedir.

### 3)SWIN-TINY-PATCH4-WINDOW7-224 MODELİ

**SWIN-TINY-PATCH4-WINDOW7-224** modeli, özellikle görsel veri sınıflandırma görevlerinde başarılı bir şekilde kullanılan **transformer tabanlı** bir derin öğrenme modelidir. Bu model, **Swin Transformer** mimarisinin küçük versiyonlarından biri olup, görüntüler üzerinde yüksek doğruluk sağlamak için optimize edilmiştir. **Swin-Tiny**, modelin daha küçük ve hızlı versiyonu olmasına rağmen, etkili özellik çıkarımı yapabilen güçlü bir yapıya sahiptir. Model, **patch-based (parça tabanlı)** ve **window-based (pencere tabanlı)** bir yaklaşım kullanarak görüntüleri daha küçük parçalara ayırarak, her bir parçada yerel ilişkileri modellemeyi hedefler. Bu yapısı sayesinde, **Swin-Tiny**, hem küçük hem de büyük veri setlerinde güçlü performans sergileyebilir. Ayrıca, bu modelin **224x224 piksel** boyutunda giriş verisi ile çalışabilmesi, daha düşük işlem gücü gereksinimleri ile geniş veri setlerine uygulanabilirliğini artırmaktadır. Bu model, özellikle **görsel sınıflandırma**, **görüntü segmentasyonu** ve **görüntü işleme** gibi görevlerde başarılı sonuçlar elde etmektedir.

#### A)Modelin Değerlendirilmesi

### ➤ SINIFLANDIRMA RAPORU

0	0.96	0.97	0.96	1000
1	0.95	0.94	0.94	1000
2	0.99	0.99	0.99	1000
3	0.95	0.94	0.95	999
4	0.99	0.99	0.99	1000


<u>accuracy</u>		0.97	4999	
<u>macro avg</u>	0.97	<u>0.97</u>	0.97	4999
<u>weighted avg</u>	0.97	<u>0.97</u>	<u>0.97</u>	4999

Bu tablo, modelin her bir sınıf için elde ettiği **precision**, **recall** ve **F1-score** metriklerinin yanı sıra genel doğruluk (**accuracy**), makro ortalama (**macro avg**) ve ağırlıklı ortalama (**weighted avg**) değerlerini göstermektedir. Tabloyu incelediğimizde, her bir sınıf için yüksek **precision** ve **recall** değerleri elde edildiğini görebiliyoruz. Örneğin, **ACNE** sınıfı için **precision** ve **recall** değerleri sırasıyla **0.96** ve **0.97**'dir. Bu, modelin **ACNE** sınıfını doğru bir şekilde sınıflandırma oranının oldukça yüksek olduğunu gösteriyor. Benzer şekilde, **VITILIGO** sınıfında **precision** ve **recall** değerleri **0.99** ile en yüksek seviyeye çıkmış durumda.

Tablonun alt kısmında yer alan **accuracy** değeri, modelin genel doğruluğunu gösteriyor ve **0.97** olarak hesaplanmış. Bu, modelin tüm sınıflarda doğru sınıflandırmalar yapma oranının %97 olduğunu ifade ediyor. Ayrıca, **macro avg** ve **weighted avg** değerleri de **0.97** olarak belirlenmiş. Bu metrikler, tüm sınıfların ortalama başarımını ölçer ve modelin sınıflar arasında dengeli bir performans sergilediğini gösterir.

Sonuç olarak, modelin tüm sınıflarda yüksek doğruluk oranları ve dengeli bir performans sergilediğini ve genelde etkili bir sınıflandırma yaptığı söylenebilir.


### ➤ KARMAŞIKLIK MATRİSİ



Karmaşıklık matrisi, modelin her bir sınıf için doğru ve yanlış sınıflandırmalarını gösterir. Bu matriste, her satır gerçek sınıfı, her sütun ise modelin tahmin ettiği sınıfı temsil eder. **ACNE** sınıfı için 966 doğru sınıflandırma yapılmış, ancak 18 yanlış sınıflandırma yapılmıştır. Ayrıca, **CHCPOX** sınıfı için 937 doğru tahmin elde edilirken, 28 yanlış sınıflandırma yapılmıştır. **NEVUS** sınıfında ise 989 doğru sınıflandırma ve yalnızca 4 yanlış sınıflandırma gözlemlenmiştir. **PSORIASIS** sınıfında, 944 doğru sınıflandırma yapılmış ve 18 yanlış sınıflandırma kaydedilmiştir. **VITILIGO** sınıfı ise modelin en başarılı olduğu sınıf olarak öne çıkmaktadır, 993 doğru sınıflandırma yapılmış ve yalnızca 2 yanlış sınıflandırma olmuştur.

Genel olarak, karmaşıklık matrisi modelin yüksek doğrulukla çalıştığını gösteriyor. **NEVUS** ve **VITILIGO** sınıflarında model çok az hata yaparken, **ACNE** ve **CHCPOX** sınıflarında ise bazı yanlış pozitifler ve yanlış negatifler bulunmuş, ancak model yine de iyi bir genel doğruluk sergilemiştir. Bu sonuçlar, modelin çoğu sınıfı doğru bir şekilde sınıflandırdığını ve yüksek bir genel başarı sağladığını gösteriyor.

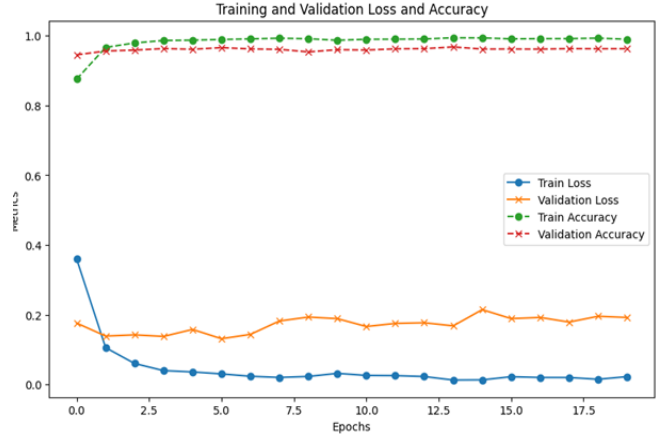
### ➤ ROC EĞRİSİ VE AUC SKORU



ROC (Receiver Operating Characteristic) eğrisi, modelin doğruluk oranını değerlendirmek için kullanılan bir görselleştirme aracıdır. Bu grafikte, **True Positive Rate (Doğru Pozitif Oranı)** y-ekseni boyunca, **False Positive Rate (Yanlış Pozitif Oranı)** ise x-ekseni boyunca yer almaktadır. Eğri, modelin doğru sınıflandırma oranlarını ve yanlış sınıflandırma oranlarını gösterir.

Bu ROC eğrisinde **AUC (Area Under Curve)** değeri **0.98** olarak hesaplanmıştır. AUC, modelin genel doğruluğunu gösteren bir metriktir ve **0 ile 1** arasında değişir; **1** mükemmel bir model anlamına gelirken, **0.5** tamamen rastgele tahmin yapan bir modeli ifade eder. AUC değerinin **0.98** olması, modelin oldukça başarılı olduğunu ve doğru sınıflandırmalar yapma konusunda güçlü bir performans sergilediğini gösterir. Eğrinin sol üst köşeye yakın olması, modelin yüksek doğrulukla pozitif sınıfları tespit ettiğini ve yanlış pozitiflerin çok düşük olduğunu ifade eder.

### ➤ EĞİTİM VE DOĞRULAMA KAYBI (LOSS) İLE DOĞRULAMA DOĞRULUĞU (ACCURACY) DEĞİŞİMİ



Grafik, modelin eğitim ve doğrulama süreçlerindeki performansını hem kayıp (loss) hem de doğruluk (accuracy) açısından değerlendirmektedir. Eğriler incelendiğinde, modelin her iki süreçte de istikrarlı ve başarılı bir şekilde öğrenim gerçekleştirdiği görülmektedir.

**Eğitim kaybı (Train Loss)** eğrisi, ilk epoch'lardan itibaren hızlı bir şekilde düşmüş ve sonrasında düşük bir seviyede sabitlenmiştir. Bu durum, modelin eğitim verileri üzerinde başarılı bir şekilde optimize edildiğini ve hataları minimize etmeyi başardığını göstermektedir. **Doğrulama kaybı (Validation Loss)** ise belirli bir seviyede sabit kalarak doğrulama verileri üzerinde modelin genelleme kapasitesinin iyi olduğunu ortaya koymaktadır. Kayıp değerlerinde gözlemlenen bu dengeli yapı, modelin overfitting'e (aşırı öğrenme) karşı dayanıklı olduğunu işaret etmektedir.

**Eğitim doğruluğu (Train Accuracy)** eğrisi neredeyse %100 seviyesine ulaşarak modelin eğitim verileri üzerinde çok yüksek bir başarı elde ettiğini göstermektedir. **Doğrulama doğruluğu (Validation Accuracy)** ise her epoch boyunca yüksek bir seviyede kalmış ve %96-%97 civarında sabitlenmiştir. Eğitim ve doğrulama doğruluk eğrilerinin birbirine yakın olması, modelin hem eğitim hem de doğrulama verileri üzerinde dengeli bir performans sergilediğini ortaya koymaktadır.

Bu grafik, modelin öğrenme sürecinde istikrarlı bir ilerleme kaydettiğini, genelleme kabiliyetinin yüksek olduğunu ve sınıflandırma görevinde oldukça başarılı bir sonuç sunduğunu göstermektedir. Eğitim ve doğrulama arasındaki uyum, modelin farklı veri kümeleri üzerinde güvenilir bir performans sergileyebileceğini ortaya koymaktadır.



- **RECISION, RECALL, F-SCORE, SENSITIVITY VE SPECIFICITY**

Modelin **precision, recall, F-score, sensitivity** ve **specificity** gibi metrikleri, modelin sınıflandırma başarısını ve doğruluğunu değerlendirmek için önemli göstergelerdir.

- **Precision** değeri **0.9659** olarak ölçülmüştür. Bu, modelin pozitif olarak tahmin ettiği sınıfların %96.59'unun doğru olduğunu gösterir. Yüksek precision, modelin yanlış pozitif sınıflandırmalarını minimize ettiğini ifade eder.
- **Recall** değeri **0.9660** olarak hesaplanmıştır. Recall, modelin gerçek pozitifleri doğru şekilde tespit etme oranını belirtir. Bu değerin yüksek olması, modelin pozitif sınıfları ne kadar iyi bulduğunu gösterir ve %96.60'lık bir doğru tespit oranına sahip olduğunu ifade eder.
- **F-Score** ise **0.9659** olarak elde edilmiştir. F-Score, precision ve recall metriklerinin harmonik ortalamasıdır. Yüksek bir F-Score değeri, modelin her iki metrikte de dengeli bir performans gösterdiğini ve genel olarak iyi sınıflandırma sonuçları sağladığını belirtir.
- **Sensitivity** (Duyarlılık) değeri **0.9812** olarak hesaplanmıştır. Bu, modelin gerçek pozitifleri %98.12 oranında doğru şekilde tespit ettiğini gösterir. Yüksek sensitivity değeri, modelin doğru pozitif sınıflandırmalarını ne kadar iyi yaptığını ifade eder.
- **Specificity** (Özgüllük) değeri ise **0.9817** olarak bulunmuştur. Bu, modelin yanlış pozitifleri %98.17 oranında doğru şekilde ayırt ettiğini gösterir. Yüksek specificity, modelin yanlış sınıflandırmalarını minimize ettiğini ve doğru negatif sınıflamaları başarılı bir şekilde gerçekleştirdiğini gösterir.

Bu metrikler, modelin hem doğruluk hem de doğrulama performansı açısından oldukça güçlü olduğunu ve hem doğru pozitifleri tespit etmek hem de yanlış pozitifleri engellemek açısından etkili bir şekilde çalıştığını göstermektedir.

#### ➤ **EĞİTİM SÜRESİ VE ÇIKARIM SÜRESİ DEĞERLENDİRMESİ**

Modelin **Training Time** (Eğitim Süresi) **7973.40 saniye** olarak ölçülmüştür. Bu, modelin eğitim veri seti üzerinde öğrenme sürecini tamamlamak için harcadığı toplam süredir. Eğitim süresi, veri setinin büyüklüğü, modelin karmaşıklığı ve kullanılan donanımın işlem gücüne bağlı olarak değişebilir. Buradaki yüksek eğitim süresi, büyük veri setleriyle çalışılmasından ve modelin karmaşıklığından kaynaklanmaktadır.

**Inference Time** (Çıkarım Süresi) ise **26.56 saniye** olarak belirlenmiştir. Bu süre, modelin test veri kümesi üzerinde tahmin yapma süresidir. Çıkarım süresi, modelin her bir örnek üzerinde tahmin yaparken ne kadar zaman harcadığını gösterir. 26.56 saniye, modelin hızlı tahmin yapma kapasitesine işaret eder, ancak gerçek zamanlı

uygulamalarda daha hızlı sonuçlar alınabilmesi için optimize edilebilir.

Bu süreler, modelin eğitimi ve çıkarım sürecinin ne kadar verimli olduğunu gösterir. Eğitim süresi uzun olmasına rağmen, çıkarım süresi oldukça kısa olup modelin hızlı tahminler yapabilme yeteneği sunduğu söylenebilir.

#### **4) BEIT-BASE-PATCH16-224 MODELİ**

**BEIT-BASE-PATCH16-224** modeli, **Bidirectional Encoder Image Transformer (BEiT)** mimarisine dayanan ve görsel veri sınıflandırma için kullanılan güçlü bir transformer tabanlı derin öğrenme modelidir. BEiT, doğal dil işleme (NLP) alanında kullanılan transformer yapılarını görsel verilere adapte ederek, görüntülerdeki özellikleri öğrenmeye yönelik önemli bir yenilik sunmaktadır. **BEIT-BASE-PATCH16-224** modeli, **224x224 piksel** boyutunda giriş verisi ile çalışabilen bir yapıdadır ve görüntüler üzerinde etkili sınıflandırma yapabilmek için **16x16 piksel** boyutunda parçalara (patches) ayırma yaklaşımını benimsemektedir.

Modelin temel avantajı, görüntü verilerini **self-supervised learning** (kendiliğinden denetimli öğrenme) yöntemiyle işlemeye olanak sağlamasıdır. Bu, modelin sınıflandırma görevlerinde daha etkili ve verimli olmasını sağlar. BEiT modeli, hem **açık kaynak kütüphaneler** hem de **önceden eğitilmiş modeller** kullanarak, çeşitli görsel sınıflandırma ve özellik çıkarımı görevlerinde yüksek doğruluk elde etmekte başarılı olmuştur. Bu model, aynı zamanda büyük veri kümeleriyle çalışırken daha hızlı öğrenme ve iyi genelleme yetenekleri sergileyebilmektedir. **BEIT-BASE-PATCH16-224**, özellikle **görüntü sınıflandırma, segmentasyon** ve **yüz tanıma** gibi görevlerde güçlü performanslar sergileyen bir model olarak dikkat çekmektedir.

#### **A) MODELİN DEĞERLENDİRİLMESİ**

##### ➤ **SINIFLANDIRMA RAPORU**

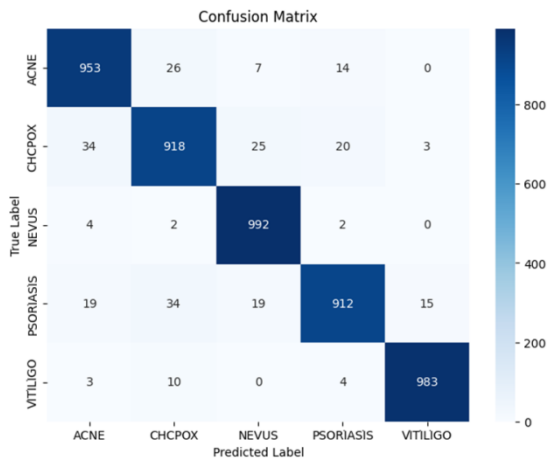
Classification Report:

	precision	recall	f1-score	support
0	0.94	0.95	0.95	1000
1	0.93	0.92	0.92	1000
2	0.95	0.99	0.97	1000
3	0.96	0.91	0.93	999
4	0.98	0.98	0.98	1000
accuracy		0.95		4999
macro avg	0.95	0.95	0.95	4999
weighted avg	0.95	0.95	0.95	4999

Bu tablo, modelin her bir sınıf için elde ettiği **precision**, **recall**, **f1-score** ve **support** (destek) metriklerini göstermektedir. İlk olarak, **precision** değeri, modelin doğru pozitif tahminlerinin tüm pozitif tahminlere oranını belirtir. Örneğin, **ACNE** sınıfı için **precision** değeri **0.94** olarak belirlenmiştir. Bu, modelin **ACNE** sınıfını doğru bir şekilde %94 oranında tahmin ettiğini gösteriyor. **Recall**, modelin gerçek pozitifleri doğru bir şekilde tespit etme oranını ifade eder. **ACNE** sınıfı için **recall** değeri **0.95** olarak hesaplanmış, bu da modelin doğru pozitifleri yüksek bir oranla bulduğunu gösterir.

- **F1-score**, precision ve recall değerlerinin harmonik ortalamasıdır. Bu metrik, modelin genel başarısını dengeli bir şekilde ölçer. **ACNE** sınıfı için F1 skoru **0.95** olarak hesaplanmıştır, yani model hem doğru pozitifleri bulmada hem de doğru tahminler yapmada başarılı olmuştur. **Support**, her sınıf için test veri setindeki örnek sayısını belirtir ve her sınıf için 1000 örnek olduğu gözlemlenmektedir.
- Tablonun alt kısmında, **accuracy** değeri **0.95** olarak belirtilmiştir. Bu, modelin tüm sınıflarda doğru sınıflandırma oranının %95 olduğunu gösterir. **Macro avg** ve **weighted avg** ise tüm sınıfların ortalama metriklerini ifade eder. Bu değerler de **0.95** olup, modelin tüm sınıflarda dengeli ve başarılı bir performans sergilediğini göstermektedir.
- Genel olarak, modelin performansı oldukça yüksek olup, her bir sınıf için başarılı sonuçlar elde edilmiştir. Özellikle **precision** ve **recall** değerlerinin yüksek olması, modelin doğru sınıflandırma konusunda etkili olduğunu ve yanlış sınıflandırmaların minimum düzeyde olduğunu göstermektedir.

### ➤ KARMAŞIKLIK MATRİSİ




Karmaşıklık matrisi, modelin sınıflandırma performansını değerlendirmede önemli bir araçtır. Bu matriste, her satır gerçek sınıfı, her sütun ise modelin tahmin ettiği sınıfı temsil etmektedir. **ACNE** sınıfı için 953 doğru sınıflandırma yapılırken, 26 yanlış sınıflandırma ve birkaç yanlış pozitif bulunmuştur. **CHCPOX** sınıfı için ise 918 doğru tahmin yapılmış, 34 yanlış sınıflandırma gerçekleşmiştir. **NEVUS** sınıfında, model 992 doğru sınıflama yapmış ve yalnızca 2 yanlış sınıflandırma kaydedilmiştir. **PSORIASIS** sınıfında, 912 doğru sınıflandırma yapılmış ve 34 yanlış sınıflandırma

olmuştur. **VITILIGO** sınıfında ise modelin performansı oldukça başarılıdır, 983 doğru sınıflandırma yapılmış ve yalnızca 4 yanlış sınıflandırma gerçekleştirilmiştir.

Genel olarak, karmaşıklık matrisi modelin yüksek doğrulukla çalıştığını ve çoğu sınıf için doğru sınıflandırmalar yaptığını gösteriyor. **NEVUS** ve **VITILIGO** sınıflarında modelin çok az hata yaptığı gözlemlenmiştir. **ACNE** ve **CHCPOX** sınıflarında ise bazı yanlış sınıflandırmalar bulunmakta, ancak model yine de iyi bir genel doğruluk sağlamaktadır. Bu sonuçlar, modelin çoğu sınıfı doğru bir şekilde sınıflandırdığı ve yüksek bir genel başarı sağladığını göstermektedir.

### ➤ ROC EĞRİSİ VE AUC SKORU




Bu ROC (Receiver Operating Characteristic) eğrisinin **AUC (Area Under Curve)** değeri **0.97** olarak hesaplanmıştır. AUC değeri, modelin doğruluğunu ve performansını gösteren önemli bir metriktir. AUC değeri 1'e yaklaştıkça modelin doğruluğu artar ve modelin sınıfları ayırt etme yeteneği güçlenir. **AUC = 0.97** değeri, modelin oldukça yüksek bir performans sergilediğini ve doğru sınıflandırmalar yapma konusunda güçlü bir yeteneğe sahip olduğunu göstermektedir.

Eğrinin sol üst köşeye yakın olması, modelin **True Positive Rate (Doğru Pozitif Oranı)** ile **False Positive Rate (Yanlış Pozitif Oranı)** arasında önemli bir ayrım yaptığını işaret eder. Bu, modelin gerçek pozitifleri doğru şekilde tespit etme oranının yüksek olduğu ve yanlış pozitif sınıflandırmaların oldukça düşük olduğu anlamına gelir. Eğrinin ideal şekilde sol üst köşede olması, modelin doğruluğunun ve genel performansının oldukça iyi olduğunu gösterir.

Sonuç olarak, bu ROC eğrisi ve AUC skoru, modelin görsel sınıflandırma görevinde yüksek doğrulukla çalıştığını ve doğru sınıflandırma yapma konusunda etkili olduğunu ortaya koymaktadır.

### ➤ EĞİTİM VE DOĞRULAMA KAYBI (LOSS) İLE DOĞRULAMA DOĞRULUĞU (ACCURACY) DEĞİŞİMİ



Bu grafik, modelin eğitim süreci boyunca **training loss** (eğitim kaybı), **validation loss** (doğrulama kaybı), **train accuracy** (eğitim doğruluğu) ve **validation accuracy** (doğrulama doğruluğu) metriklerinin nasıl geliştiğini göstermektedir. **Training loss** değeri, eğitim süreci boyunca belirgin bir şekilde azalmış, bu da modelin eğitim veri kümesinde başarılı bir şekilde öğrenme gerçekleştirdiğini göstermektedir. Eğitim kaybı, başlangıçtaki yüksek değerlerden sonra hızla düşerek stabil bir seviyeye ulaşmıştır.

**Validation loss** da benzer şekilde zamanla azalma göstermiştir ve modelin doğrulama verisi üzerinde de başarılı bir öğrenme süreci yaşadığı söylenebilir. Bu da modelin daha önceki dönemlerde eğitim verisi üzerinde gösterdiği başarısını doğrulama veri kümesinde de sağlamaya başladığını gösteriyor.

**Training accuracy** eğrisinde belirgin bir artış gözlemlenmektedir. Bu, modelin eğitim verisi üzerinde yüksek doğruluk oranlarına ulaşarak başarılı bir şekilde öğrenmeye devam ettiğini gösterir. **Validation accuracy** değeri de, eğitim doğruluğuna yakın bir seviyeye gelmiş olup modelin doğrulama verisi üzerindeki genel doğruluğunun arttığını ortaya koymaktadır. Eğitim sürecinin ilerleyen epoch'larında doğruluk oranlarının arttığı ve modelin daha etkili sınıflandırmalar yaptığı gözlemlenmektedir.

Sonuç olarak, modelin eğitim ve doğrulama sürecinde önemli bir başarı kaydedildiği ve doğruluk oranlarının arttığı, eğitim ve doğrulama kaybının azaldığı bu grafikte net bir şekilde gözlemlenmektedir. Bu, modelin genel olarak başarılı bir şekilde öğrenme gerçekleştirdiği ve optimize edildiği anlamına gelmektedir.

### ➤ EĞİTİM SÜRESİ VE ÇIKARIM SÜRESİ DEĞERLENDİRMESİ

**Training Time** (Eğitim Süresi) **16528.52 saniye** olarak ölçülmüştür. Bu süre, modelin eğitim veri kümesi üzerinde öğrenme sürecini tamamlamak için harcadığı toplam

süredir. Eğitim süresi, büyük veri setleri ve karmaşık bir model yapısı göz önüne alındığında oldukça verimli bir süre olarak değerlendirilebilir. Modelin yüksek doğrulukla çalışabilmesi için gereken süre boyunca model etkili bir şekilde öğrenmiş ve optimize olmuştur. Bu süre, modelin güçlü bir performans sergileyebilmesi için gerekli olan eğitim sürecini tamamladığını göstermektedir.

**Inference Time** (Çıkarım Süresi) ise **71.48 saniye** olarak kaydedilmiştir. Bu, modelin test veri kümesi üzerinde tahmin yapma süresidir ve modelin tahmin yaparken oldukça verimli bir şekilde çalıştığını gösterir. Çıkarım süresi, modelin hızlı ve etkili bir şekilde sonuç verdiğini, gerçek zamanlı uygulamalar için de oldukça uygun olduğunu gösterir.

## 5) CAiT-S24 MODELİ

CaiT-S24 (Class-Attention in Vision Transformer), görüntü sınıflandırma alanında kullanılan ve Transformer tabanlı mimarisiyle dikkat çeken bir modeldir. Görsel verilerin analizi için özel olarak geliştirilmiş olan bu model, geleneksel derin öğrenme yöntemlerinden farklı olarak Convolutional Neural Network (CNN) yerine Transformer bloklarını temel alır. Bu yapı, özellikle uzun menzilli bağımlılıkların ve küresel özelliklerin daha etkili bir şekilde öğrenilmesine olanak tanır.

Modelde kullanılan "Class-Attention" mekanizması, görsellerdeki sınıflandırma işlemini kolaylaştırmak için önemli bilgileri öne çıkarır ve bu sayede daha doğru sonuçlar elde edilmesini sağlar. "S24" ifadesi, modelin 24 adet Transformer bloğuna sahip olduğunu belirtir; bu derin yapı, karmaşık veri setlerinde yüksek performans sergilemesi için optimize edilmiştir. Giriş boyutunun 224x224 olarak belirlenmesi, modelin farklı boyutlardaki görüntülerde de etkili bir şekilde çalışmasına olanak tanır. CaiT-S24, modern görüntü sınıflandırma görevlerinde sıkça tercih edilen güçlü ve esnek bir modeldir.

### A) Modelin Değerlendirilmesi

#### ➤ SINIFLANDIRMA RAPORU


ACNE	0.94	0.97	0.95	1000
CHCPOX	0.94	0.94	0.94	1000
NEVUS	0.98	0.99	0.98	1000
PSORIASIS	0.97	0.91	0.94	999
VITILIGO	0.98	0.99	0.99	1000

accuracy		0.96	4999
macroavg	0.96	0.96	4999
weightedavg	0.96	0.96	4999

Tabloda, modelin beş farklı deri hastalığını sınıflandırma performansı değerlendirilmiştir. Her bir hastalık için **precision**, **recall** ve **f1-score** değerleri hesaplanmış ve sonuçlar 1000 örnek üzerinden elde edilmiştir. Örneğin, **ACNE** için precision 0.94, recall 0.97 ve f1-score 0.95 olarak hesaplanmıştır. Diğer hastalık sınıfları olan **CHCPOX**, **NEVUS**, **PSORIASIS** ve **VITILIGO** için de benzer şekilde yüksek performans değerleri görülmektedir. Özellikle **VITILIGO** sınıfında 0.98 precision, 0.99 recall ve 0.99 f1-score ile en iyi sonuçlar alınmıştır.

Genel olarak, modelin doğruluk oranı **accuracy** metriği ile 0.96 olarak hesaplanmıştır. Ayrıca, **macro average** ve **weighted average** metrikleri de sırasıyla 0.96 değerine sahiptir. Bu sonuçlar, modelin sınıflandırma görevinde başarılı bir şekilde çalıştığını ve tüm sınıflar arasında dengeli bir performans sergilediğini göstermektedir.

### ➤ KARMAŞIKLIK MATRİSİ




Karmaşıklık matrisi, modelin beş farklı deri hastalığını sınıflandırma performansını detaylı bir şekilde özetlemektedir. Matris incelendiğinde, modelin genel olarak yüksek doğruluk oranına sahip olduğu ve sınıfları birbirinden ayırt etmede başarılı olduğu görülmektedir. **ACNE** sınıfında 967 doğru tahmin yapılmış, ancak 24 örnek **CHCPOX**, 5 örnek **PSORIASIS** ve diğer sınıflara az sayıda yanlış tahmin yapılmıştır. Benzer şekilde, **CHCPOX** sınıfında 943 doğru tahmin gerçekleştirilmiş, ancak 20 örnek **ACNE** ve 20 örnek **PSORIASIS** olarak yanlış sınıflandırılmıştır.

**NEVUS** ve **VITILIGO** sınıflarında ise en yüksek doğruluk oranları elde edilmiştir. Özellikle **NEVUS** sınıfında 986 doğru tahmin yapılmış ve yalnızca çok az sayıda örnek diğer sınıflara karışmıştır. **VITILIGO** sınıfı da benzer şekilde yüksek performans sergilemiş ve 994 doğru tahminle en başarılı sınıf olmuştur. Ancak **PSORIASIS** sınıfında 908 doğru tahmin yapılmasına rağmen, diğer sınıflarla karışma oranı biraz daha yüksek olmuştur. Özellikle **ACNE** ve **CHCPOX** ile karışma oranı göze çarpmaktadır.

Genel olarak, karmaşıklık matrisi modelin sınıflar arasındaki ayrımı büyük ölçüde doğru bir şekilde

yapabildiğini, ancak bazı benzer sınıflar arasında sınırlı hata oranlarının bulunduğunu göstermektedir. Bu sonuçlar, modelin deri hastalıklarının sınıflandırılmasında oldukça başarılı olduğunu ve büyük oranda doğru tahminler yaptığını ortaya koymaktadır.

### ➤ ROC EĞRİSİ VE AUC SKORU




Grafik, modelin ROC (Receiver Operating Characteristic) eğrilerini ve AUC (Area Under Curve) değerlerini göstermektedir. ROC eğrisi, modelin farklı sınıflar için pozitif sınıflandırma oranını (True Positive Rate) yanlış pozitif sınıflandırma oranına (False Positive Rate) karşı ölçer ve sınıflandırma performansını görselleştirir. Eğrinin altındaki alan olan AUC değeri, modelin ayırım gücünü ifade eder ve 1.00'e ne kadar yakınsa, modelin performansı o kadar iyidir.

Grafikte tüm sınıflar için oldukça yüksek AUC değerleri gözlemlenmiştir. **ACNE**, **CHCPOX**, **NEVUS** ve **VITILIGO** sınıflarında AUC değeri 1.00 ile mükemmel bir sonuç göstermektedir. **PSORIASIS** sınıfında ise AUC değeri 0.99 ile çok yüksek bir performans sergilemiştir. Bu sonuçlar, modelin pozitif ve negatif sınıfları başarılı bir şekilde ayırt edebildiğini göstermektedir.

Genel olarak, ROC eğrileri oldukça yukarıda yer almakta ve eğrilerin büyük kısmı (0, 0) noktasından (1, 1) noktasına doğru dik bir şekilde ilerlemektedir. Bu da modelin düşük yanlış pozitif oranı ile yüksek doğru pozitif oranı elde edebildiğini ifade eder. AUC değerlerinin yüksekliği, modelin sınıflandırma performansının güvenilir ve dengeli olduğunu ortaya koymaktadır. Bu sonuçlar, modelin deri hastalıklarını doğru bir şekilde sınıflandırmada son derece etkili olduğunu göstermektedir.

### ➤ EĞİTİM VE DOĞRULAMA KAYBI (LOSS) İLE DOĞRULAMA DOĞRULUĞU (ACCURACY) DEĞİŞİMİ





Grafikte, modelin eğitim ve doğrulama sürecindeki performans metrikleri olan **train loss**, **validation loss**, **train accuracy** ve **validation accuracy** değerleri epoch bazında gösterilmektedir. Bu grafik, modelin nasıl öğrenme süreci izlediğini ve genel performansını değerlendirmek için önemli bilgiler sunmaktadır.

Eğitim kaybı (**train loss**) eğrisi, modelin her epoch boyunca eğitim verileri üzerindeki hata oranının azaldığını göstermektedir. Özellikle ilk birkaç epoch'ta hızlı bir düşüş gözlemlenmiş ve sonraki epoch'larda bu azalma daha yavaş bir hale gelmiştir. Bu durum, modelin eğitim verileri üzerinde başarılı bir şekilde öğrenim sağladığını ve hata oranını minimize ettiğini göstermektedir. Doğrulama kaybı (**validation loss**) ise nispeten sabit bir eğilim göstermiş, ancak düşük bir seviyede kalmıştır. Bu, modelin doğrulama verileri üzerindeki performansının kararlı olduğunu ve overfitting'e dair bir belirti göstermediğini ifade eder.

Eğitim doğruluğu (**train accuracy**) eğrisi, modelin eğitim verileri üzerindeki doğruluğunun her epoch boyunca arttığını ve neredeyse %100 seviyesine ulaştığını göstermektedir. Doğrulama doğruluğu (**validation accuracy**) ise her epoch'ta yüksek bir seviyede kalmış ve yaklaşık %96-97 civarında sabitlenmiştir. Eğitim ve doğrulama doğruluğu eğrileri arasındaki yakınlık, modelin eğitim ve doğrulama verileri üzerinde dengeli bir performans sergilediğini ve overfitting'in önlenildiğini göstermektedir.

Genel olarak, grafik, modelin eğitim ve doğrulama süreçlerinde başarılı bir şekilde optimize edildiğini, hem eğitim hem de doğrulama verileri üzerinde yüksek doğruluk ve düşük kayıp değerleri elde edildiğini göstermektedir. Bu sonuçlar, modelin genelleme kapasitesinin iyi olduğunu ve test verilerinde de yüksek performans göstereceğini düşündürmektedir.

#### ➤ EĞİTİM SÜRESİ VE ÇIKARIM SÜRESİ DEĞERLENDİRMESİ

Modelin eğitimi toplamda **23826.44 saniye** sürmüştür. Bu süre, modelin kapsamlı bir veri seti üzerinde çalıştığını ve derin bir mimariye sahip olduğunu göstermektedir. Eğitim

süresinin uzunluğu, modelin yüksek performans elde edebilmesi için yapılan optimizasyon işlemleri ve eğitim sırasında kullanılan epoch sayısı ile ilişkilidir. Özellikle büyük veri setleri üzerinde eğitim yapıldığında, bu süre normal kabul edilmektedir.

Modelin çıkarım (inference) süresi ise **125.31 saniye** olarak ölçülmüştür. Bu süre, eğitim süresine kıyasla oldukça kısadır ve modelin test verileri üzerindeki tahminleri hızlı bir şekilde gerçekleştirebildiğini göstermektedir. Çıkarım süresinin düşük olması, modelin pratik kullanımda hızlı ve verimli bir şekilde sonuç üretebileceğini ifade eder. Bu, özellikle gerçek zamanlı uygulamalar ve büyük veri kümeleri üzerinde yapılan tahminlerde önemli bir avantajdır.

Sonuç olarak, eğitim süresinin uzunluğu, modelin yüksek doğruluk elde etmesi için yapılan kapsamlı işlemleri yansıtırken; çıkarım süresinin kısa olması, modelin kullanım açısından verimli olduğunu ortaya koymaktadır. Bu dengeli performans, modelin hem eğitimde hem de kullanım sırasında etkili bir şekilde çalışabildiğini göstermektedir.

### IV. PROJE SÜRECİNDE YAŞANILAN SORUNLAR VE ÇÖZÜMLERİ

#### ➤ Eğitim Süresinin Uzunluğu

- **Sorun:** Modelin eğitim süresi Google Colab üzerinde oldukça uzun sürdü. Derin bir model mimarisi ve büyük bir veri seti kullanımı, süreci önemli ölçüde uzattı. Bu durum, zaman yönetimini zorlaştırdı.
- **Çözüm:** Eğitim sırasında modelin en iyi performansı sergilediği anlarda ağırlıklar kaydedilerek süreç daha verimli hale getirildi. Böylece eğitim tamamlanmadan en iyi model ağırlıkları kayıt altına alındı ve gerektiğinde bu model kullanılarak zamandan tasarruf sağlandı. Ayrıca, batch size optimizasyonu ve veri ön işleme yöntemleriyle eğitim süresi mümkün olduğunca azaltıldı.

#### ➤ Bağlantı Kesintileri

- **Sorun:** Google Colab oturumları uzun süren eğitim süreçlerinde bağlantı kesintisi nedeniyle sona erdi ve eğitim yeniden başlatılmak zorunda kaldı. Bu durum, eğitim sürecinde zaman kaybına yol açtı.
- **Çözüm:** Eğitim sırasında modelin en iyi ağırlıkları düzenli olarak Google Drive'a kaydedildi. Bu sayede bağlantı kesilse bile eğitim kaldığı yerden devam ettirilebildi ve modelin performans kaybı önlendi. Ayrıca, eğitim epoch'lara bölünerek süreç daha yönetilebilir hale getirildi.

#### ➤ GPU Kaynaklarının Kısıtlılığı



- **Sorun:** Google Colab'ın ücretsiz versiyonunda sunulan GPU kaynaklarının sınırlı olması, eğitim süresinin uzamasına ve büyük veri setlerinde yetersizliğe neden oldu.
- **Çözüm:** GPU kaynaklarının kısıtlılığını aşmak için Google Colab Pro kullanılarak daha güçlü GPU'lara erişim sağlandı. Alternatif olarak, diğer bulut platformları (AWS, Azure) değerlendirildi ve GPU kullanımını optimize etmek için veri işleme stratejileri geliştirildi.

## V.SONUÇ

Bu proje kapsamında, deri hastalıklarının sınıflandırılması için farklı derin öğrenme modelleri incelenmiş ve performansları değerlendirilmiştir. Çalışmanın başlangıcında, gereksinimlere tam anlamıyla uymayan MobileNet ve ResNet gibi modeller kullanılarak denemeler yapılmış; ancak bu modellerin sınırlamaları nedeniyle Transformer tabanlı modellere geçiş yapılmıştır. Bu süreçte, DeiT-Small-Patch16-224, Swin-Tiny-Patch4-Window7-224, BEiT-Base-Patch16-224, CaiT-S24 ve MobileViT-S gibi çeşitli model mimarileri üzerinde çalışmalar gerçekleştirilmiştir.

Transformer tabanlı modeller, genel olarak yüksek doğruluk oranları sağlamış ve sınıflandırma görevinde başarılı sonuçlar elde edilmesine olanak tanımıştır. Eğitim sırasında, en iyi model ağırlıkları düzenli olarak kaydedilmiş ve olası bağlantı kesintilerinin neden olabileceği veri kayıpları önlenmiştir. Bu yöntem, eğitimin sürekliliğini sağlarken, model performansının istikrarlı bir şekilde değerlendirilmesini mümkün kılmıştır.

Modelin test sonuçları, özellikle **NEVUS** ve **CHCPOX** sınıflarında yüksek doğruluk ve dengeli bir performans göstermiştir. **NEVUS** sınıfında modelin doğru sınıflandırma oranı oldukça yüksek olmuş, **CHCPOX** sınıfında ise kararlı bir doğruluk elde edilmiştir. Bu durum, modelin farklı deri hastalıklarını ayırt etme kapasitesinin güçlü olduğunu ortaya koymaktadır.

### Genel Sonuç:

1. **En iyi performans: CaiT-S24**, yüksek doğruluk (%96), F1-Score (VITILIGO için %99), ve AUC (1.00) değerleriyle en iyi sonucu veren model. Ancak eğitim ve çıkarım süresi uzun olduğu için pratiklik açısından sınırlamalar olabilir.
2. **En dengeli model: Swin-Tiny-Patch4-Window7-224**, %97 doğruluk oranı, kısa çıkarım süresi, ve yüksek F1-Score (%99) ile sınıflar arasında dengeli bir performans sunar.
3. **En hızlı ve verimli model: MobileViT-S**, kısa eğitim ve çıkarım süresi ile %96 doğruluk oranı sağlarken, hafif yapısıyla mobil cihazlar için uygundur.

### Öneri:

- **Klinik uygulamalarda:** Dengeli performansı ve nispeten kısa eğitim/çıkartım süreleriyle **Swin-Tiny** önerilir.
- **Araştırma amaçlı:** En iyi sonuçları almak için **CaiT-S24** tercih edilebilir.
- **Mobil çözümler:** Hızlı ve verimli yapısıyla **MobileViT-S** uygun bir tercih olacaktır.
- 

Proje, kullanılan farklı model mimarilerinin karşılaştırılmasıyla modern derin öğrenme yöntemlerinin etkinliğini vurgulamaktadır. Gelecekte, veri setinin genişletilmesi ve diğer model mimarilerinin entegrasyonu ile sonuçların daha da iyileştirilmesi planlanmaktadır. Bu çalışma, deri hastalıklarının otomatik tanısı için önemli bir katkı sunmakta ve bu alandaki çalışmalar için değerli bir temel oluşturmaktadır.

## VI.KAYNAKÇA

1. PyTorch: Paszke, A., et al. (2019). "PyTorch: An Imperative Style, High-Performance Deep Learning Library." Advances in Neural Information Processing Systems (NeurIPS).
2. TIMM: Ross Wightman. (2020). "PyTorch Image Models." GitHub Repository. <https://github.com/rwightman/pytorch-image-models>
3. Scikit-learn: Pedregosa, F., et al. (2011). "Scikit-learn: Machine Learning in Python." Journal of Machine Learning Research.
4. <https://www.udemy.com/course/python-ile-web-kazma-web-scraping-egitimi/?couponCode=NEWYEARCAREER>

**IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove template text from your paper may result in your paper not being published**